

WiRE-TPP / Signed-Wishart

Протокол экспериментальной программы,
corrected all-12 и полный алгоритм обучения

Сводка воспроизводимости, последовательных абляций THP/COTIC, matched-DGP экспериментов и отрицательных результатов с точной фиксацией фактически применённых метапараметров.

Итог. Совокупность экспериментов не подтверждает устойчивого общего преимущества Signed-Wishart по кластеризации. На corrected all-12 COTIC остаётся сильным и слегка выигрывает у по-W в среднем, тогда как THP в среднем немного проигрывает. На специально согласованном Wishart-DGP обнаружен слабый средний эффект, но его знак меняется между seeds. Обучаемая ν и увеличение числа train-MC samples проблему не устранили.

Правило чтения результатов. Выбор checkpoint и конфигурации производится по максимальной validation purity, затем по меньшему validation NLL. Test используется только описательно после выбора. Строки, где решение было принято вручную или после просмотра test, прямо помечены и не считаются подтверждающим сравнением.

Дата фиксации:	7 августа 2026 г.
Рабочая директория:	C:\Users\missi\Documents\WiRETPP
GPU:	NVIDIA GeForce RTX 4060 Laptop, 8188 MiB
Основные backbones:	THP и COTIC
Главная задача:	кластеризация marked event sequences

Содержание

1 Краткое резюме и статус доказательств	2
1.1 Что действительно установлено	2
1.2 Что не следует утверждать	2
2 Карта экспериментальной программы	2
3 Данные, split и метрики	3
4 Модель и полный алгоритм обучения	4
4.1 Базовый mixture TPP	4
4.2 $K=1$ pretraining и expansion	4
4.3 Latent Wishart random effect	4
4.4 Frozen exploration Wishart	5
4.5 Signed convex intensity transform	5
4.6 Wishart gate и MC-маргинализация	5
4.7 Global unbalanced OT dual	6
4.8 Hyperprior, DPP и полный loss	6
4.9 Physical backward elimination	6
4.10 Один optimizer step	7
4.11 Validation selection и test	7
5 Corrected all-12: точный протокол	7
5.1 Состав benchmark	7
5.2 Гиперпараметры Wishart all-12	7
5.3 Seed 0: полный corrected Wishart результат	8
5.4 Трёхсидовая сводка all-12	10
5.5 Разбор $\sin_K5_C5$ по seeds	12
6 Ранние и промежуточные эксперименты	12
6.1 Published snapshot и 300-epoch retraining	12
6.2 Signed DGP: moderate против strong	13
6.3 THP fixed-split, MC и InfoMax	13
6.4 Two-phase COTIC: сильный, но односидовый результат	13
7 Поздние THP sweeps на $\sin_K5_C5$	13
7.1 Frozen backbone LR $\times$ warmup	13
7.2 $\eta_\alpha \times K=1$ pretraining length	14
7.3 Big-protocol $\beta_0 = 1$ и η_α	14
7.4 Overcomplete backbone LR, частичный sweep	14
8 Matched Wishart random-effect DGP	14
8.1 Почему первый DGP был невалиден	14
8.2 Исправленная генерация	14
8.3 Gain 1/3/5 и paired результат gain 3	15
9 Обучаемая ν и Monte Carlo	15
9.1 Непрерывная параметризация ν	15
9.2 Fixed 25, fixed 37 и learned 37	16
9.3 LR_ν и train-MC samples	16
10 Обоснование составных частей: итоговая матрица	16
11 Вычислительная среда и memory safety	17
12 Ошибки протокола, исправления и источники неопределённости	17
13 Рекомендуемый следующий подтверждающий эксперимент	18
14 Артефакты и воспроизводимость	18
14.1 Главные источники all-12	18
14.2 Отчёты предшествующих фаз	18
14.3 Поздние sweeps и matched DGP	19
14.4 Реализация алгоритма	19
15 Финальный вывод	19

1 Краткое резюме и статус доказательств

1.1 Что действительно установлено

1. Репозиторий и опубликованные checkpoints воспроизводимы на уровне inference: повторный MC-аудит фиксированных весов дал отклонения suffix NLL не более $6.1 \cdot 10^{-4}$ и purity не более $1.88 \cdot 10^{-3}$.
2. В ранней 300-epoch реконструкции Wishart улучшал predictive suffix NLL во всех шести paired-сравнениях, но clustering metrics заметно менялись при retraining. Значит, MC evaluation был стабилен, а optimization path — нет.
3. На corrected all-12, объединённом по seeds 0, 1, 2, COTIC-Wishart имеет среднюю test purity 0.98874 против 0.98715 у COTIC no-W (+0.00159). THP-Wishart имеет 0.97245 против 0.97677 (−0.00432).
4. Самый трудный случай — sin_K5_C5 с THP. На трёх seeds THP-Wishart даёт 0.8667 ± 0.0900 test purity, no-W — 0.9250 ± 0.0260 . COTIC на том же датасете остаётся почти идеальным: 0.9883 ± 0.0076 для Wishart.
5. Заморозка encoder во время overcomplete elimination и отдельная K=1-инициализация улучшали отдельные односидовые точки, но эффект сильно зависел от pretraining length и не переносился как единый устойчивый рецепт.
6. Matched block-local Wishart-DGP с gain 3 дал среднюю validation purity 0.8417 для Wishart против 0.8250 для no-W, но paired deltas равны +0.125, −0.025, −0.050. Средний знак положителен, устойчивого эффекта нет.

1.2 Что не следует утверждать

- Нельзя утверждать, что latent Wishart всегда улучшает кластеризацию: aggregate THP и несколько сильных DGP-сценариев это опровергают.
- Нельзя считать la1_bos полным воспроизведением опубликованного LaL. Это только fixed-K BOS-control с общим COTIC; random-walk, split/merge/ delete и EM-процедура LaL в нём отсутствуют.
- Нельзя выбирать $\eta_\alpha = 10^{-4}$ по test. В $\beta_{00} = 1$ sweep validation winner был 10^{-5} ; 10^{-4} был затем зафиксирован как инженерное решение для следующей постановки.
- Нельзя интерпретировать движение α или ν как доказательство идентифицированного random effect без paired improvement в held-out metrics.

2 Карта экспериментальной программы

Дата	Эксперимент	Статус	Главный результат
01.08	Published-checkpoint audit и полный 300-epoch retraining	завершён	Fixed-weight inference воспроизводим; Wishart улучшает NLL, clustering retraining нестабилен.
01.08	Signed K3C5 DGP, 3 seeds	завершён	Moderate heterogeneity: signed лучше $\alpha = 0$; strong: signed хуже на всех seeds.
02.08	THP sin_K5_C5, fixed split, 5 seeds	завершён	Wishart +0.019 test purity в среднем, но сохраняет four-mode collapse.

Дата	Эксперимент	Статус	Главный результат
02.08	Optuna, frozen exploration, MC и scheduler	завершён	Нет устойчивой точки; больше MC не помогает; beta curriculum даёт лишь +0.003 validation purity.
03.08	Two-phase K5_C5 COTIC	завершён, seed	1 K=1 pretrain + freeze + DPP дал val/test 0.995/1.000; требуется multiseed.
04–05.08	Original и corrected all-12	завершён	12 datasets × 2 architectures × 2 variants × 3 seeds; COTIC стабилен, THP sin_K5 нестабилен.
06.08	Frozen backbone LR × warmup, 25 jobs	завершён	Лучший seed-0 val/test 0.945/0.910 при $\eta_{bb} = 3 \cdot 10^{-4}$, warmup 50.
06.08	$\eta_\alpha \times K=1$ pretrain, 25 jobs	завершён	Лучший val 0.935 при pretrain 300 и $\eta_\alpha = 10^{-5}$; test 0.890 описательно.
07.08	Big-protocol beta ₀ = 1, η_α sweep, 5 jobs	завершён	Validation winner 10 ⁻⁵ : val/test 0.910/0.885; 10 ⁻⁴ : 0.905/0.925.
07.08	Overcomplete backbone LR sweep, 7 planned	частичный, 5/7	Из завершённых лучший 10 ⁻⁶ : val/test 0.870/0.835; прогон остановлен.
07.08	Первый full matched Wishart-RE suite, 9 planned	остановлен, 2/9	Обе модели collapsed в один cluster; постановка признана дефектной.
07.08	Исправленный block-local DGP gain 1/3/5	debug шён	Gain 3 дал слабый средний Wishart эффект, но paired sign нестабилен.
07.08	Fixed/learned ν , LR _{ν} , MC 1/2/4	debug шён	Fixed $\nu = 25$ выбран validation rule; learnable ν и больше MC purity не улучшили.

Ограничение. В workspace есть дополнительные smoke, unit и аварийные каталоги. Они используются для аудита реализации, но не включаются в количественный benchmark. Статусы running в некоторых suite_progress.json являются stale metadata после ручной остановки и не означают живой процесс.

3 Данные, split и метрики

Траектория записывается как

$$x_i = \{(t_{ij}, c_{ij})\}_{j=1}^{n_i}, \quad c_{ij} \in \{1, \dots, C\}, \quad t_{ij} \leq T_i.$$

Во всех DAN all-12 экспериментах $C = 5$. Dataset name кодирует истинное число кластеров: K2, K3, K4, K5. Рассматриваются три семейства: обычные Hawkes-процессы K*_C5, синусоидальные sin_K*_C5 и усечённые trunc_K*_C5.

Для all-12 и поздних sweeps используется один и тот же split: numpy.RandomState(42).shuffle, затем 80/10/10. Model seeds меняют инициализацию, minibatches и Wishart sampling, но не split. Для sin_K5_C5 это 1600/200/200 траекторий.

Множество	Разрешено	Запрещено
Train	gradients, OT dual, hyperprior, pruning score	использование labels в objective
Validation	purity/NLL checkpoint selection	parameter fitting и test-dependent rule
Test	один descriptive pass после выбора	выбор checkpoint, LR, α , ν или DGP

Основная метрика model selection — validation purity; при равенстве purity выбирается меньший validation NLL per exposure. Test-метрики: purity, ARI, NMI, NLL per exposure. Purity допускает many-to-one matching и поэтому дополняется ARI/NMI и размерами кластеров.

Обоснование. Purity была выбрана для сопоставимости с LaL. ARI и NMI нужны, поскольку высокая purity может скрывать дублирование одной истинной моды двумя предсказанными компонентами. NLL проверяет predictive fit, но не заменяет clustering metric: во многих runs NLL улучшался одновременно с ухудшением purity.

4 Модель и полный алгоритм обучения

4.1 Базовый mixture TPP

Shared encoder H_θ строит историю, а component head G_{ϕ_k} задаёт C положительных intensities $\lambda_{kc}^{(0)}(t | H_\theta)$. Для компоненты k :

$$\ell_{ik} = \sum_j \log \lambda_{k,c_{ij}}(t_{ij}) - \int_0^{T_i} \sum_{c=1}^C \lambda_{kc}(t) dt.$$

Backbone может быть THP или COTIC; Wishart layer не меняет его контракт.

4.2 K=1 pretraining и expansion

Сначала одна компонента обучается по обычному TPP NLL. Затем её head копируется в $K_0 = K^* + 5$ блоков:

$$\phi_k = \phi_1 + \varepsilon_k, \quad \varepsilon_k \sim \mathcal{N}(0, \sigma_{exp}^2 I).$$

В all-12 pretraining длится 10 optimizer steps, $\sigma_{exp} = 0.01$.

Обоснование. K=1 отделяет обучение общей временной динамики от allocation компонент. Малый шум разрушает permutation symmetry, не уничтожая общий масштаб intensity. Overcomplete запас из пяти heads даёт backward elimination несколько кандидатов на каждую финальную компоненту.

4.3 Latent Wishart random effect

При текущем K размер latent matrix равен $D = KC$. Обучаемая средняя матрица задаётся Cholesky-параметром:

$$\Omega = LL^T, \quad \text{tr } \Omega = D, \quad \text{diag}(L) = \text{softplus}(r) + 10^{-5}.$$

Траекторный random effect:

$$W_i \sim \text{Wishart}_D(\nu, \Omega/\nu), \quad \mathbb{E}[W_i] = \Omega.$$

В all-12 $\nu(K) = \lfloor 1.5KC \rfloor$: для sin_K5 это 75 при $K = 10$ и 37 при $K = 5$.

Обоснование. Одна и та же W_i используется для route и intensity transform на всей траектории. Trace normalization удаляет неидентифицируемый общий scale, Cholesky гарантирует SPD, а изменение ν вместе с D поддерживает примерно сопоставимый уровень sampling noise при pruning.

4.4 Frozen exploration Wishart

Во время train независимо сэмплируется $W_{exp} \sim \text{Wishart}(\nu_e, I/\nu_e)$ и применяется curriculum

$$W_t = (1 - \beta_t)W_{learn} + \beta_t W_{exp},$$

$$x_t = \frac{t-1}{T-1}, \quad \beta_t = \beta_0 \frac{e^{-d_\beta x_t} - e^{-d_\beta}}{1 - e^{-d_\beta}}.$$

В all-12 $\beta_0 = 0.9$, $d_\beta = 5$, $\nu_e = 200$; в позднем sweep $\beta_0 = 1$. На validation, pruning и test всегда $\beta = 0$.

Обоснование. Curriculum должен задержать раннюю фиксацию случайного basin и затем точно вернуть inference к learned law. Эксперименты показывают, что сам по себе этот механизм даёт лишь малый и нестабильный выигрыш.

4.5 Signed convex intensity transform

Из W строится correlation matrix и off-diagonal coupling:

$$R = \text{diag}(W)^{-1/2} W \text{diag}(W)^{-1/2}, \quad B = R - I.$$

Пусть $\lambda^{(0)} \in \mathbb{R}_+^{KC}$ — base intensities, $a = \lambda^{(0)} / (\epsilon + \sum_d \lambda_d^{(0)})$ и $q = \text{softplus}^{-1}(\lambda^{(0)})$. Тогда

$$p = Ba, \quad \tilde{q} = (1 - \alpha)q + \alpha p, \quad \tilde{\lambda} = \text{softplus}(\tilde{q}), \quad \alpha \in [0, 1].$$

В all-12 $\alpha_0 = 0.1$, projected parameterization, $\eta_\alpha = 10^{-4}$.

Обоснование. Correlation normalization отделяет interaction structure от scale; $B = R - I$ удаляет self-effect. Exact inverse softplus сохраняет исходную TPR интенсивность при $\alpha = 0$. Projected $[0, 1]$ ограничивает деформацию, а финальный softplus гарантирует положительность.

4.6 Wishart gate и MC-маргинализация

Для sample s cluster gate равен нормированной диагональной массе его $C \times C$ блока:

$$g_{isk} = \log \frac{\sum_{c=1}^C (W_{is})_{kc, kc}}{\sum_{r=1}^K \sum_{c=1}^C (W_{is})_{rc, rc}}.$$

Wishart интегрируется, сохраняя component index:

$$S_{ik} = \log \sum_{s=1}^S \exp(\ell_{isk} + g_{isk}) - \log S.$$

Обоснование. Gate и intensity используют одну latent W_i , поэтому route и random effect согласованы. Log-sum-exp даёт стабильную дифференцируемую аппроксимацию marginal likelihood.

4.7 Global unbalanced OT dual

При target marginal $q_k = 1/K$, temperature τ , penalty ρ и dual $u \in \mathbb{R}^K$:

$$r_{ik} = \text{softmax}_k \left(\frac{S_{ik} - u_k}{\tau} \right), \quad \bar{q}_k(u) = \text{softmax}_k \left(\log q_k + \frac{u_k}{\rho} \right),$$

$$\mathcal{F} = -\tau \frac{1}{B} \sum_i \log \sum_k e^{(S_{ik} - u_k)/\tau} - \rho \log \sum_k e^{\log q_k + u_k/\rho}.$$

Primal минимизирует $\mathcal{F}$, dual максимизирует; после update $u \leftarrow u - \text{mean}(u)$. В all-12 $\rho = 5$ постоянно, $\eta_u = 0.01$ для Wishart и 0.05 для исторического no-W control.

Обоснование. Global dual мягко препятствует component collapse, не навязывая равный баланс внутри каждого microbatch. Центрирование устраняет additive gauge. Разный dual LR у W/no-W является историческим confound и учитывается в интерпретации paired results.

4.8 Hyperprior, DPP и полный loss

Mean-matrix penalty:

$$\mathcal{L}_\Omega = \frac{\gamma_\Omega}{2N_{tr}} (\text{tr } \Omega - \log \det \Omega - D).$$

Functional DPP, если включён:

$$K_{kr}^{DPP} = \exp \left(-\frac{\|v_k - v_r\|^2}{2h^2} \right) + \epsilon_{DPP} \delta_{kr}, \quad \mathcal{L}_{DPP} = -\frac{1}{K} \log \det K^{DPP}.$$

Итоговая primal objective:

$$\mathcal{L} = \mathcal{F} + \mathcal{L}_\Omega + w_{DPP}(t) \mathcal{L}_{DPP}.$$

В all-12 $\gamma_\Omega = 1.566$, а $w_{DPP} = 0$. DPP применялся только в поздних frozen-encoder постановках.

Обоснование. Hyperprior одновременно является SPD barrier и shrinkage к identity. DPP нужен после cloning для функционального разведения heads, но после выбора target K repulsion может мешать likelihood fine-tuning; поэтому в двухфазном протоколе он затухает до нуля.

4.9 Physical backward elimination

После warmup 300 выполняются пять удалений на шагах 300, 400, 500, 600, 700. На всех train trajectories с S_{prune} и $\beta = 0$ считаются full score L_{full} и score физически уменьшенной копии L_{-j} :

$$\Delta_j = L_{-j} - L_{full}, \quad j^* = \arg \min_j \Delta_j.$$

Удаляются head j^* и его C координат в Ω ; сохраняется principal submatrix, затем trace нормируется до нового D . Primal optimizer пересоздаётся, dual обнуляется и меняет размерность, lineage обновляется.

Обоснование. Full-train marginal NLL измеряет непосредственный ущерб без labels и validation leakage. Common random numbers уменьшают variance разности. Physical removal, в отличие от masking, уменьшает и head, и latent dimension; optimizer moments после смены геометрии больше невалидны.

4.10 Один optimizer step

1. Вычислить β_t , ρ_t , DPP weight и, если применимо, encoder LR.
2. Взять A microbatches по B trajectories; effective batch BA .
3. Для каждой траектории сэмплировать S_{train} matrices, построить signed intensities, gates и S_{ik} .
4. Посчитать $\mathcal{F}$, hyperprior и DPP; вызвать backward от $\mathcal{L}/A$.
5. Clip global primal norm до 20, сделать Adam step, project α .
6. Сделать maximizing Adam step dual и центрировать u .
7. На pruning step выполнить physical removal и reset optimizers.
8. Оценить validation с $\beta = 0$; checkpoint eligible только при $K = K^*$.

4.11 Validation selection и test

Лучший eligible checkpoint максимизирует validation purity; tie-break — меньший validation NLL. После train загружаются model state и dual лучшего checkpoint. Test оценивается один раз с $\beta = 0$ и $S_{test} = 16$ без updates.

5 Corrected all-12: точный протокол

5.1 Состав benchmark

- 12 datasets: K2--K5, sin_K2--sin_K5, trunc_K2--trunc_K5; везде $C = 5$.
- 2 architectures: THP и COTIC.
- 2 variants: no-W и Signed-Wishart.
- 3 model seeds: 0, 1, 2; split seed всегда 42.
- Всего в объединённом анализе 144 runs. Corrected seed-0 Wishart suite содержит 24/24; seeds 1–2 suite — 96/96; seed-0 no-W взят из предыдущего завершённого suite.

5.2 Гиперпараметры Wishart all-12

Параметр	Значение	Комментарий
K_0, K^*	$K^* + 5, K^*$	Всегда ровно пять eliminations.
K=1 pretraining	10 steps	Seed 0 W построил собственный K=1; seeds 1–2 W переиспользовал paired no-W checkpoint byte-identically.
Warmup / prune interval / post-prune	300 / 100 / 600	Prune steps 300, 400, 500, 600, 700; total 1300.
Head clone noise	0.01	Symmetry breaking.
Neural LR	10^{-3}	Фактический общий optimizer для shared backbone и heads.
Historical backbone metadata LR	10^{-5}	Записан в config/result, но не создаёт отдельную group; history логирует 10^{-3} .
Omega LR / alpha LR	$10^{-2} / 10^{-4}$	Без weight decay.
Dual LR / ρ	$10^{-2} / 5$	ρ постоянно 5.
Weight decay / global clip	$10^{-5} / 20$	Weight decay только neural parameters.

Параметр	Значение	Комментарий
Physical batch / accumulation	16 / 8	Effective batch 128.
Eval batch	16	Validation на каждом optimizer step.
MC train/val/test/prune	2 / 8 / 16 / 8	Independent fixed-seed RNG streams.
α_0 , parameterization, mode	0.1, projected, convex	$\alpha \in [0, 1]$, temperature 1.
$\nu(K)$	$\lfloor 1.5KC \rfloor$	Integer fixed degrees of freedom.
β_0 , decay, ν_e	0.9, 5, 200	Exponential-to-zero; eval всегда $\beta = 0$.
Mean hyperprior	1.566	Trace/logdet penalty.
DPP	0	Bandwidth/jitter metadata неактивны.
Encoder freeze / ramp	false / неактивен	Это не frozen protocol 06.08.
Selection	max val purity, min val NLL	Test не участвует.

Ограничение. No-W control не является идеально однофакторной абляцией Wishart: его dual LR равен 0.05, physical batch/accumulation 64/2, а seed-0 correction использует другой K=1 checkpoint. Effective batch в обоих variants равен 128, а seeds 1–2 имеют exact paired K=1 reuse.

5.3 Seed 0: полный corrected Wishart результат

В следующих таблицах W — corrected Wishart, no-W — исторический paired control. Значения test описательны; LaL — опубликованный mean из локального reference-файла:

artifacts/dan_all_arch_newwishart_beta_cotic7_seed0_20260802/PUBLISHED_DAN_PURITY.csv

Dataset	Arch	Val W	Test W	ARI W	NLL W	Test no-W	α	Step	LaL
K2_C5	COTIC	1.000	1.000	1.000	1.9915	1.000	0.1079	747	0.970
K3_C5	COTIC	1.000	1.000	1.000	1.9742	1.000	0.1077	800	0.850
K4_C5	COTIC	1.000	1.000	1.000	1.8997	1.000	0.1165	1095	0.900
K5_C5	COTIC	1.000	1.000	1.000	1.9231	0.965	0.1083	1283	0.840
sin_K2_C5	COTIC	1.000	1.000	1.000	3.4839	1.000	0.1097	721	0.990
sin_K3_C5	COTIC	1.000	0.9917	0.9759	0.6453	0.9917	0.1034	1258	0.990
sin_K4_C5	COTIC	0.9813	0.9438	0.8484	0.8200	0.9500	0.1030	1001	0.920
sin_K5_C5	COTIC	0.990	0.980	0.9474	3.0326	0.990	0.1117	1281	0.920
trunc_K2_C5	COTIC	1.000	1.000	1.000	3.7149	1.000	0.1336	702	1.000
trunc_K3_C5	COTIC	0.975	0.9667	0.9040	4.2103	0.9833	0.1455	825	0.960
trunc_K4_C5	COTIC	0.9938	0.9875	0.9655	3.8171	0.9875	0.1383	706	0.990
trunc_K5_C5	COTIC	0.950	0.975	0.9379	3.9446	0.970	0.1395	713	0.940
K2_C5	THP	1.000	1.000	1.000	2.4279	1.000	0.1753	1288	0.970
K3_C5	THP	1.000	1.000	1.000	2.3733	1.000	0.1683	1288	0.850
K4_C5	THP	1.000	0.9938	0.9844	2.2501	0.9875	0.1814	1274	0.900
K5_C5	THP	0.995	0.980	0.9521	2.4411	0.990	0.1778	1223	0.840
sin_K2_C5	THP	0.975	1.000	1.000	3.6827	1.000	0.1099	1300	0.990
sin_K3_C5	THP	1.000	0.9833	0.9524	1.0541	0.9917	0.1055	1280	0.990
sin_K4_C5	THP	0.9063	0.9063	0.7774	1.1977	0.900	0.1026	1265	0.920
sin_K5_C5	THP	0.865	0.870	0.7166	3.3949	0.910	0.1390	1267	0.920
trunc_K2_C5	THP	1.000	1.000	1.000	3.6242	1.000	0.1528	797	1.000
trunc_K3_C5	THP	0.975	0.975	0.9269	4.1716	0.9667	0.1588	858	0.960
trunc_K4_C5	THP	0.9938	0.9875	0.9655	3.8055	0.9938	0.1719	1001	0.990
trunc_K5_C5	THP	0.950	0.975	0.9399	3.9370	0.980	0.1626	851	0.940

Для seed-0 THP sin_K5: best validation NLL 3.0898, lineage [0, 2, 3, 4, 9], $\alpha \in [0.10009, 0.13921]$, median/max alpha-gradient 4.047/20.553, clip fraction 0.8977, runtime 1898.5 s. Финальная Ω имеет eigenvalue range [0.0257, 17.8022]; train soft marginal L1 до uniform равен 0.0969.

5.4 Трёхсидовая сводка all-12

Dataset	Arch	W test mean $\pm$ SD	no-W test mean $\pm$ SD	Δ	W ARI mean	LaL
K2_C5	COTIC	1.0000 $\pm$ 0.0000	1.0000 $\pm$ 0.0000	0.0000	1.0000	0.970
K3_C5	COTIC	1.0000 $\pm$ 0.0000	1.0000 $\pm$ 0.0000	0.0000	1.0000	0.850
K4_C5	COTIC	1.0000 $\pm$ 0.0000	1.0000 $\pm$ 0.0000	0.0000	1.0000	0.900
K5_C5	COTIC	1.0000 $\pm$ 0.0000	0.9817 $\pm$ 0.0144	0.0183	1.0000	0.840
sin_K2_C5	COTIC	1.0000 $\pm$ 0.0000	1.0000 $\pm$ 0.0000	0.0000	1.0000	0.990
sin_K3_C5	COTIC	0.9917 $\pm$ 0.0000	0.9889 $\pm$ 0.0048	0.0028	0.9759	0.990
sin_K4_C5	COTIC	0.9458 $\pm$ 0.0219	0.9563 $\pm$ 0.0108	-0.0104	0.8555	0.920
sin_K5_C5	COTIC	0.9883 $\pm$ 0.0076	0.9867 $\pm$ 0.0029	0.0017	0.9691	0.920
trunc_K2_C5	COTIC	1.0000 $\pm$ 0.0000	1.0000 $\pm$ 0.0000	0.0000	1.0000	1.000
trunc_K3_C5	COTIC	0.9778 $\pm$ 0.0127	0.9778 $\pm$ 0.0048	0.0000	0.9352	0.960
trunc_K4_C5	COTIC	0.9896 $\pm$ 0.0036	0.9813 $\pm$ 0.0063	0.0083	0.9710	0.990
trunc_K5_C5	COTIC	0.9717 $\pm$ 0.0029	0.9733 $\pm$ 0.0058	-0.0017	0.9311	0.940
K2_C5	THP	1.0000 $\pm$ 0.0000	1.0000 $\pm$ 0.0000	0.0000	1.0000	0.970
K3_C5	THP	1.0000 $\pm$ 0.0000	1.0000 $\pm$ 0.0000	0.0000	1.0000	0.850
K4_C5	THP	0.9958 $\pm$ 0.0036	0.9958 $\pm$ 0.0072	0.0000	0.9897	0.900
K5_C5	THP	0.9867 $\pm$ 0.0058	0.9933 $\pm$ 0.0058	-0.0067	0.9682	0.840
sin_K2_C5	THP	1.0000 $\pm$ 0.0000	0.9958 $\pm$ 0.0072	0.0042	1.0000	0.990
sin_K3_C5	THP	0.9889 $\pm$ 0.0048	0.9889 $\pm$ 0.0048	0.0000	0.9681	0.990
sin_K4_C5	THP	0.8958 $\pm$ 0.0295	0.8917 $\pm$ 0.0260	0.0042	0.7519	0.920
sin_K5_C5	THP	0.8667 $\pm$ 0.0900	0.9250 $\pm$ 0.0260	-0.0583	0.7423	0.920
trunc_K2_C5	THP	1.0000 $\pm$ 0.0000	1.0000 $\pm$ 0.0000	0.0000	1.0000	1.000
trunc_K3_C5	THP	0.9722 $\pm$ 0.0048	0.9694 $\pm$ 0.0048	0.0028	0.9192	0.960
trunc_K4_C5	THP	0.9917 $\pm$ 0.0036	0.9896 $\pm$ 0.0036	0.0021	0.9775	0.990
trunc_K5_C5	THP	0.9717 $\pm$ 0.0029	0.9717 $\pm$ 0.0104	0.0000	0.9317	0.940

Arch	W purity	no-W purity	Δ	W wins/ties/losses	Δ NLL	Runtime W/no-W
THP	0.97245	0.97677	-0.00432	9/18/9	+0.00212	7.76/3.49 h
COTIC	0.98874	0.98715	+0.00159	11/20/5	-0.01548	8.83/3.23 h

В среднем по datasets THP-Wishart выше опубликованного LaL mean на 8 из 12, равен на одном и ниже на трёх; COTIC-Wishart выше на 10, равен на одном и ниже на одном. Это не paired reproduction LaL, а масштабная внешняя reference line. Совокупный recorded runtime 144 runs составляет 23.31 GPU-hours; peak VRAM в all-12 не мониторился отдельным sampler.

5.5 Разбор `sin_K5_C5` по seeds

Arch	Variant	Seed	Val	Test	ARI	Test NLL
THP	no-W	0	0.920	0.910	0.7828	3.4083
THP	W	0	0.865	0.870	0.7166	3.3949
THP	no-W	1	0.935	0.955	0.8879	3.2421
THP	W	1	0.940	0.955	0.8877	3.2715
THP	no-W	2	0.915	0.910	0.7859	3.2756
THP	W	2	0.830	0.775	0.6227	3.2985
COTIC	no-W	0	0.975	0.990	0.9764	3.0296
COTIC	W	0	0.990	0.980	0.9474	3.0326
COTIC	no-W	1	0.980	0.985	0.9627	3.0484
COTIC	W	1	0.990	0.990	0.9734	3.0047
COTIC	no-W	2	0.975	0.985	0.9627	3.0233
COTIC	W	2	0.985	0.995	0.9866	3.0042

Итог. All-12 показывает не универсальную пользу Wishart, а interaction с backbone. COTIC устойчиво решает `sin_K5`; THP имеет seed-dependent collapse, особенно W seed 2. Небольшой NLL gain THP W seed 0 не компенсирует ухудшение clustering.

6 Ранние и промежуточные эксперименты

6.1 Published snapshot и 300-epoch retraining

На 1200 trajectories (split 90/45/1065) были проверены NHP, THP, COTIC и две component parameterizations. Таблица показывает новый retraining seed 0.

Модель	no-W NLL	W NLL	W-no-W	W purity
NHP/output split	3.5515	3.4580	-0.0935	0.936
NHP/lal fixed	3.5776	3.4719	-0.1057	0.923
THP/output split	3.6236	3.5128	-0.1108	0.661
THP/lal fixed	3.5368	3.4969	-0.0399	0.925
COTIC/output split	3.9159	3.6408	-0.2751	0.934
COTIC/lal fixed	3.8771	3.6732	-0.2039	0.709

Wishart улучшил suffix NLL во всех шести comparisons, но THP/output-split purity упал с опубликованных 0.951 до 0.661, COTIC/lal-fixed — с 0.892 до 0.709. Внутренняя MC-SD была мала: нестабилен optimizer basin, не evaluation.

6.2 Signed DGP: moderate против strong

Трёхсидовый NHP-эксперимент использовал exact signed K3C5 DGP. В таблице разность $\text{signed}-\alpha = 0$ по NLL; отрицательное лучше.

DGP	Signed NLL	Signed $-\alpha = 0$	Purity	ARI
Zero	3.55375 ± 0.06726	-0.00591 ± 0.01049	0.8514	0.7155
Moderate	3.48672 ± 0.06376	-0.03394 ± 0.01543	0.9531	0.8673
Strong	3.56485 ± 0.10071	$+0.02086 \pm 0.02296$	0.9336	0.8177

Moderate выиграл на всех seeds, strong проиграл на всех. Увеличение model ν до 30/60/120 не исправило strong DGP. Уменьшение η_α монотонно удерживало α около 0.1 и улучшало NLL, что больше похоже на ограничение вредной interaction, чем на успешную идентификацию.

6.3 THP fixed-split, MC и InfoMax

Variant	Val purity	Test purity	ARI	1-to-1 accuracy	Все 5 мод
THP no-W	0.808 ± 0.010	0.710 ± 0.014	0.507	0.649 ± 0.016	0/5
WiRE-THP	0.819 ± 0.004	0.729 ± 0.007	0.547	0.656 ± 0.015	0/5
WiRE + InfoMax 5	0.810 ± 0.010	0.740 ± 0.017	0.555	0.705 ± 0.049	2/5
WiRE + InfoMax 10	0.811 ± 0.007	0.749 ± 0.019	0.543	0.723 ± 0.052	3/5

Обе plain-модели использовали пять predicted components, но покрывали только четыре true modes. Train MC samples 2/4/8 дали val purity 0.820/0.820/0.820; validation MC 8–128 и test MC 16–128 также не меняли purity. Значит, four-mode collapse не был следствием недостаточного MC.

6.4 Two-phase COTIC: сильный, но односидовый результат

На K5_C5: K=1 pretrain 300, expansion $1 \rightarrow 10$, frozen encoder, DPP 0.1, pruning 300–700, затем DPP $\rightarrow 0$, backbone LR $0 \rightarrow 10^{-5}$ и $\rho : 5 \rightarrow 50$. Получено val/test purity 0.995/1.000, ARI/NMI 1.000. Direct joint no-W/W controls дали test 0.665/0.825.

Ограничение. Это один dataset и один seed. Поздний all-12 использовал иной протокол: pretrain 10, encoder unfrozen, DPP 0, $\rho = 5$. Поэтому результат доказывает силу двухфазной optimization geometry, а не чистый эффект Wishart.

7 Поздние THP sweeps на sin_K5_C5

7.1 Frozen backbone LR $\times$ warmup

25 seed-0 jobs: backbone LR $\{10^{-5}, 3 \cdot 10^{-5}, 10^{-4}, 3 \cdot 10^{-4}, 10^{-3}\} \times \text{warmup} \{300, 100, 50, 25, 10\}$. Encoder frozen до target K , physical batch 8, accumulation 8, effective batch 64. Validation top points:

Backbone LR	Warmup	Val	Val NLL	Test	ARI
$3 \cdot 10^{-4}$	50	0.945	3.2431	0.910	0.7859
$3 \cdot 10^{-4}$	300	0.940	3.2091	0.910	0.7857
10^{-4}	300	0.940	3.2401	0.895	0.7495
10^{-5}	300	0.935	3.3018	0.905	0.7782
$3 \cdot 10^{-4}$	10	0.930	3.2155	0.905	0.7778

Односидовый best превосходит THP no-W all-12 seed0 validation 0.920, но descriptive test 0.910 лишь совпадает с no-W. Это показывает улучшение basin selection на validation, не доказанный test gain.

7.2 $\eta_\alpha \times K=1$ pretraining length

25 jobs с independently built $K=1$ checkpoints. Лучший validation result: pretrain 300, $\eta_\alpha = 10^{-5}$, val/test 0.935/0.890. При той же длине $\eta_\alpha = 10^{-4}$ дал 0.925/0.885; 10^{-3} — 0.930/0.895. Короткий pretrain 10–100 в основном снижал val до 0.795–0.830.

Итог. Длина $K=1$ pretraining оказалась важнее точной настройки η_α . В этом grid нет evidence, что быстрый alpha optimizer восстанавливает кластеризацию; на лучших точках α остаётся около 0.10–0.22.

7.3 Big-protocol $\beta_0 = 1$ и η_α

Здесь воспроизведён фактический общий neural optimizer all-12: backbone и heads всегда 10^{-3} , exact $K=1$ checkpoint all-12 reused. Единственные изменения — $\beta_0 = 1$ и η_α .

η_α	Val	Val NLL	Test	ARI	Best α
10^{-5}	0.910	3.0623	0.885	0.7367	0.1041
10^{-4}	0.905	3.0660	0.925	0.8164	0.1378
10^{-3}	0.900	3.0822	0.900	0.7666	0.3716
$3 \cdot 10^{-4}$	0.900	3.0889	0.895	0.7543	0.2175
$3 \cdot 10^{-5}$	0.805	3.0675	0.735	0.5468	0.1123

Validation rule выбирает 10^{-5} . После этого для matched-DGP вручную зафиксировано 10^{-4} . Это допустимый новый design choice, но его нельзя обосновывать более высоким test 0.925.

7.4 Overcomplete backbone LR, частичный sweep

Из 7 запланированных завершены 5. До target K heads имели LR 10^{-3} , backbone — swept LR; после target backbone возвращался к 10^{-3} за 200 steps. Лучшие завершённые точки: 10^{-6} val/test 0.870/0.835; frozen 0 — 0.855/0.845; $3 \cdot 10^{-6}$ — 0.840/0.805. Прогон остановлен, поэтому он не задаёт финальную конфигурацию.

8 Matched Wishart random-effect DGP

8.1 Почему первый DGP был невалиден

Первый full suite содержал 2000 sequences и имел почти идеальную oracle block-mass routing accuracy 0.998, но обе обучаемые модели collapsed в один cluster: val/test purity 0.2, ARI/NMI 0.0. Hidden W был структурирован, но observable event data недостаточно отражали random effect, а $K=1$ cloning и слабая early separation не создавали usable clusters. Suite остановлен после 2/9 jobs.

8.2 Исправленная генерация

Новый DGP сохраняет синусоидальный COTIC-like kernel, но вводит block-local activity. Для каждой trajectory её истинный $K \times C$ block получает нормированную local activity a^{loc} ; между блоками используется global activity a^{glob} :

$$p = \gamma_{in}(B \odot M_{in})a^{loc} + \gamma_{out}(B \odot M_{out})a^{glob}.$$

Финальная DGP intensity использует тот же convex transform с $\alpha_{true} = 0.35$. Текущая постановка: $K = C = 5$, 400 sequences/cluster в полном плане, horizon 20, $\nu_{data} = 25$, baseline totals [0.8, 6.5, 6.5, 16.0, 2.3], $\gamma_{in} = 3$, $\gamma_{out} = 0.25$.

Full preflight на 2000 sequences до block-local gain имел mean events 123.592, oracle routing 0.9935, rate relative SD 0.0200, validation ridge-LDA accuracy 0.710 и all-data k-means ARI 0.7483. Gain-3 debug data на 400 sequences имели mean events 171.423, rate relative SD 0.0351, ridge-LDA 0.725 и k-means ARI 0.7038. То есть effect стал сильнее, но задача одновременно стала интенсивнее.

8.3 Gain 1/3/5 и paired результат gain 3

Preflight DGP summary:

Within gain	Rate rel. SD	Ridge-LDA acc	k-means ARI	Mean events
1	0.01395	0.875	0.7864	134.87
3	0.03510	0.725	0.7038	171.42
5	0.05128	0.675	0.6546	212.78

Gain 3, short COTIC, 3 seeds:

Seed	Val no-W	Val W	Δ val	Test no-W/W	ARI no-W/W	NLL no-W/W
0	0.775	0.900	+0.125	0.675/0.775	0.5196/0.6178	3.1214/3.1234
1	0.825	0.800	-0.025	0.725/0.750	0.5842/0.5585	3.1665/3.0966
2	0.875	0.825	-0.050	0.750/0.800	0.6040/0.6519	3.1119/3.1026
Mean	0.825	0.8417	+0.0167	0.7167/0.7750	0.5692/0.6094	3.1333/3.1076

Итог. Гипотеза получила только слабое exploratory evidence: средние purity, ARI и NLL лучше у Wishart, но validation sign положителен лишь на одном из трёх seeds. Этого недостаточно для запуска дорогого full 9-task suite как confirmatory benchmark.

9 Обучаемая ν и Monte Carlo

9.1 Непрерывная параметризация ν

Для learnable mode реализовано

$$\nu = D + (\nu_{max} - D)\sigma(r_\nu), \quad D < \nu < \nu_{max},$$

и weak log-scale prior

$$\mathcal{L}_\nu = \frac{\gamma_\nu}{2} \left(\log \frac{\nu}{\nu_0} \right)^2.$$

Wishart sample строится дифференцируемым Bartlett factor: нижнетреугольные off-diagonal элементы standard normal, диагональ $\sqrt{\chi^2_{\nu-j+1}}$, реализованная через reparameterized gamma. Fixed integer branch оставлен byte-compatible.

Обоснование. Bounded sigmoid гарантирует $\nu > D$, а Bartlett decomposition разрешает gradient по continuous degrees of freedom. Отдельный optimizer group и слабый prior предотвращают мгновенный уход к границе.

9.2 Fixed 25, fixed 37 и learned 37

Mode	Val purity	Val NLL	Test purity	Test ARI	Selected ν
Fixed 25	0.8583	3.10216	0.7667	0.6013	25
Fixed 37	0.8500	3.10753	0.7750	0.6094	37
Learned from 37	0.8583	3.10600	0.7417	0.5684	37.505 mean

По validation rule fixed 25 выигрывает tie по purity меньшим NLL. Learned ν по seeds выбрал 37.232, 37.809, 37.475; gradients были малы, параметр остался рядом со стартом.

9.3 LR_ν и train-MC samples

Seed 0: $\eta_\nu = 10^{-3}$ дал val 0.850 и $\nu = 37.23$; $3 \cdot 10^{-3}$ — 0.825 и 37.84; 10^{-2} — 0.825 и 40.78. Большой LR сдвигает ν вверх, но purity ухудшается.

S_{train}	Val purity	Val NLL	Selected ν	$ g_\nu _{max}$	Runtime	Peak VRAM
1	0.825	3.12222	37.274	0.01343	30.6 s	1803 MiB
2	0.825	3.12380	37.531	0.00893	32.8 s	2029 MiB
4	0.800	3.10675	36.985	0.00435	35.8 s	2921 MiB

Итог. Больше MC samples действительно уменьшает gradient noise и при $S = 4$ улучшает validation NLL, но primary clustering metric падает. Проблема не объясняется только MC variance.

10 Обоснование составных частей: итоговая матрица

Составная часть	Теоретическая роль	Экспериментальный статус
K=1 pretrain	Отделить density representation от cluster allocation.	Сильный practical effect; слишком короткий pretrain ухудшает THP.
Clone + noise	Сохранить scale и разрушить symmetry.	Необходим; неправильная cloning scale приводила к collapse matched-DGP.
Overcomplete K_0	Дать elimination запас кандидатов.	Работает на простых DAN; не гарантирует все true modes на sin-K5 THP.
Shared W_i	Связать routing и trajectory-level intensity effect.	NLL benefit встречается часто; clustering benefit backbone- и seed-dependent.
Correlation R и $B = R - I$	Отделить связи от scale и self-effect.	Численно стабильно; само по себе не обеспечивает идентификацию.
Projected α	Ограничить interaction и сохранить exact no-effect point.	Большой η_α часто вреден; optimum обычно близок к 0.1.
Exploration β_t	Отложить ранний basin lock-in.	Средний эффект мал; $\beta_{t0} = 1$ не дал устойчивой победы.
Global OT dual	Препятствовать component collapse глобально.	Критически важен; weak/incorrect setting collapsed matched-DGP.

Составная часть	Теоретическая роль	Экспериментальный статус
Hyperprior Ω	SPD barrier и shrinkage.	Предотвращает вырождение; learned matrices всё же могут быть анизотропны.
Functional DPP	Развести клонированные heads до pruning.	Сильный в one-seed two-phase COTIC; factorized multiseed evidence отсутствует.
Physical elimination	Удалять least harmful head без labels.	Даёт auditable lineage; дорого по runtime, чувствительно к representation drift.
Encoder freeze	Сделать соседние pruning decisions сопоставимыми.	Улучшил отдельные THP/COTIC runs; all-12 его не использовал.
Gradient accumulation	Стабилизировать global marginal при ограниченной VRAM.	Позволяет effective batch 128; memory-safe variants сохраняют семантику.
MC 2/8/16/8	Баланс variance и стоимости.	Увеличение train/eval MC purity не улучшило; retained default оправдан.
Learnable ν	Адаптировать variance random effect.	Реализуемо и стабильно, но в debug не улучшило validation-selected clustering.
Validation-only selection	Исключить test leakage.	Обязательный инвариант; ручная фиксация после test не считается подтверждением.

11 Вычислительная среда и memory safety

Исходная реконструкция: Windows, Python 3.12.13, PyTorch 2.12.0+cu126, NumPy 2.3.5, pandas 2.2.3, EasyTPP 0.2.1, RTX 4060 Laptop 8188 MiB. All-12 использовал physical batch 16/64 и effective batch 128 без отдельного VRAM sampler. Поздние sweeps были закреплены за GPU 0. Они использовали physical batch 8, pruning batch 2, accumulation 16 и guard при sampled dedicated VRAM ≥ 7000 MiB.

После 06.08 physical-removal scoring сначала генерирует прежнюю RNG-группу Wishart samples, затем строит THP traces адаптивными microbatches с budget не более 512 padded events; candidate scores и common-random-number semantics сохраняются, CUDA cache очищается между candidate copies.

Обоснование. Memory adaptation меняет только физическое разбиение. Effective batch, Wishart samples и candidate RNG остаются прежними, поэтому сравнение scores не превращается в другую статистическую процедуру.

12 Ошибки протокола, исправления и источники неопределённости

- Metadata LR mismatch.** Config all-12 содержит backbone LR 10^{-5} , history — 10^{-3} . Фактический history имеет приоритет.
- Original seed-0 Wishart rows.** В старом suite использовались прежние W settings; в основной таблице они заменены corrected 24/24.
- Неидеальный seed-0 pairing.** Corrected W и historical no-W имеют разные K=1 checkpoints. Seeds 1–2 paired byte-identically.

4. **Different no-W dual LR.** Значит, all-12 W-noW — сравнение исторических variants, не чистая абляция одного слоя.
5. **Single-seed tuning.** Большинство Aug6–7 grids оптимизировалось на seed 0; их ranking нельзя считать multiseed generalization.
6. **Multiple exploration.** После многих grids validation metrics сами становятся объектом adaptive search; нужен fresh confirmatory seed set.
7. **LaL scope.** Published means — внешняя reference; локальный BOS-control неполон и не заменяет LaL random walk.

13 Рекомендуемый следующий подтверждающий эксперимент

Новый дорогой sweep сейчас не оправдан. Если работу продолжать, минимальный научно чистый протокол должен быть следующим:

1. Зафиксировать один matched gain-3 DGP generator до обучения и сохранить data hashes; не менять DGP после просмотра metrics.
2. Сравнить только no-W и W с exact shared K=1 checkpoint, одинаковыми neural/dual LRs, batch/RNG schedule и без test-guided tuning.
3. Зафиксировать W: $\eta_\alpha = 10^{-4}$ как заранее объявленный design, $\nu = 25$ fixed, $S_{train/val/test} = 2/8/16$, $\beta_0 = 1$.
4. Использовать минимум 10 fresh model seeds; primary endpoint — paired validation purity W-noW, secondary — ARI/NMI/NLL. Test открыть один раз после заморозки анализа.
5. Отдельно, а не в том же comparison, проверить two-phase freeze+DPP, чтобы не смешивать effect Wishart с effect optimization geometry.
6. Полный LaL comparison называть таковым только после реализации его random-walk/split-delete protocol; до этого использовать термин “LaL-style fixed-K BOS control”.

14 Артефакты и воспроизводимость

14.1 Главные источники all-12

artifacts/dan_all12_best_elimination_corrected_seed0_20260805/summary.csv

artifacts/dan_all12_best_elimination_seed0_20260804/summary.csv

artifacts/dan_all12_best_elimination_seeds1_2_20260805/summary.csv

scripts/run_two_phase_all12_benchmark.py

artifacts/dan_all_arch_newwishart_beta_cotic7_seed0_20260802/PUBLISHED_DAN_PURITY.csv

Для точного THP sin_K5 источниками являются config.json, history.csv, progress.json, pruning_events.json и result.json внутри соответствующего run directory. При конфликте фактического LR используются history/progress.

14.2 Отчёты предшествующих фаз

REPRODUCTION_REPORT_20260801.md

SIGNED_EXPERIMENT_REPORT_20260801.md

THP_WISHART_OPTUNA_EXPLORATION_REPORT_20260802.md

THP_WISHART_SPLIT42_EPOCHWISE_REPORT_20260802.md

COTIC_TWO_PHASE_WIRE_REPORT_20260803.md

14.3 Поздние sweeps и matched DGP

```
artifacts/dan_sin_k5_thp_frozen_backbone_lr_warmup_seed0_20260806/sweep_summary.csv
artifacts/dan_sin_k5_thp_frozen_lr_alpha_pretrain_seed0_20260806/sweep_summary.csv
artifacts/dan_sin_k5_thp_big_protocol_beta1_lr_alpha_seed0_20260807/sweep_summary.csv
configs/experiments/wishart_re_sin_k5_cotic_comparison.json
artifacts/_debug_wishart_re_blocklocal_gain3_preflight_20260807/dgp_audit.json
artifacts/_debug_wishart_re_blocklocal_gain3_preflight_20260807/summary.csv
artifacts/_debug_wishart_re_gain3_nu_fixed25_20260807/summary.csv
artifacts/_debug_wishart_re_gain3_nu_learned37_20260807/summary.csv
artifacts/_debug_wishart_re_gain3_nu_learned37_mc4_val8_20260807/summary.csv
```

14.4 Реализация алгоритма

```
src/lal_wishart/models/wishart_math.py
src/lal_wishart/models/signed_wishart.py
src/lal_wishart/models/latent_wishart_attention_nhp.py
src/lal_wishart/train/fit_latent_wishart_attention_nhp.py
src/lal_wishart/reproduction/wishart_re_sin_k5c5.py
scripts/run_wishart_re_sin_k5_cotic_comparison.py
```

15 Финальный вывод

Итог. Главный положительный результат проекта — не универсальный clustering gain, а воспроизводимая и технически целостная процедура trajectory-level Wishart marginalization, physical elimination и validation-only selection. Predictive NLL нередко улучшается. Однако clustering advantage зависит от backbone, initialization и DGP; на THP sin_k5 Wishart может ухудшать результат, а matched-DGP gain остаётся нестабильным по seeds. Поэтому текущий научно корректный вывод — отрицательный/неопределённый, а не “Wishart лучше”. Следующий шаг должен быть один заранее зарегистрированный paired multiseed эксперимент, а не очередной seed-0 sweep.